




Natural Language Processing

Concepts and practical examples



Il **Natural Language Processing** (NLP) è un'area dell'intelligenza artificiale e della linguistica computazionale che studia **modelli** e **algoritmi** per **l'analisi**, la **comprensione** e la **generazione** del linguaggio naturale.

L'obiettivo è quello di ottenere sistemi computazionali di **elaborare testi** e **discorsi** ed estrarre da essi **informazioni rilevanti**.

Si basa principalmente su **modelli**:

- Statistici
- Machine Learning
- Deep Learning


Introduction

Esempi di applicazione:

- Spam Detection
- Chatbot

Tipo di apprendimento

- Supervised
- Unsupervised



Agenda

- Introduction
- Preprocessing
- Part of Speech and Named Entities
- Sentiment Analysis
- Vectorizing Text
- Topic Modelling
- Text Classifier
- Case Study: Classify Fake News

1. General Cleaning: ha lo scopo di garantire l'affidabilità dei dati:

1. Organizzazione
2. Pulizia dei testi
3. Rimozione di tutto ciò che può portare ad errori

2. Rimozione del rumore: consiste nell'eliminare dai dati tutte quelle component di informazione che non hanno valore

3. Porre i dati nella forma corretta

Preprocessing

- Lowercasting
- Remove stopwords
- Regex (**regular expression**)
- Tokenization
- Stemming
- Lemmatization
- N-grams


Tokenizzazione è il processo che converte il nostro testo in unità più piccolo. Queste unità sono note come token. La tokenizzazione delle parole è la forma più comune (le singole parole del testo diventano un token) ma i token possono anche essere frasi, sottoword o singoli caratteri a seconda del caso d'uso.

Stemming: si riferisce a standardizzare il testo, ossia la riduzione delle parole alla loro forma base. Ad esempio, parole come "connecting" o 'connected' saranno ridotte alla forma base "connect". Lo stemming funziona rimuovendo il suffisso/la desinenza della parola, ma a volte può portare alla formazione di una forma base priva di significato o non corretta.


Lemmatization: riduce la parola alla sua forma base più significativa e garantisce che non perda il suo significato. La lemmatizzazione funziona in modo più intelligente, facendo riferimento a un dizionario predefinito contenente il contesto delle parole e utilizzandolo quando riduce la parola alla sua forma base.

POS Tagging and NER

POS sta per Part of Speech e associa ad ogni parola una label riferita alla parte di testo che rappresenta (nome, pronome, verbo...)



NER sta per Name Entity Recognition e associa ad ogni parte del testo un label riferita al tipo di entità che rappresenta (persona, luogo...)



Practical Example

Lavoriamo su l dataset `bbc_news.csv`

Step da eseguire:

- Caricamento dati (lavoriamo sulla colonna titolo)
- Pulizia. (stop words, punctuation, tokenize, lemmatizing)
- POS tagging (nomi, verbi, aggettivi più frequenti)
- NER (persone più frequenti, luoghi più frequenti)

Cos'è

La **Sentiment Analysis** è una tecnica dell'NLP che permette di identificare e classificare automaticamente le **emozioni** espresse in un testo, come **positivo**, **negativo** o **neutro**.

Obiettivi principali

- Comprendere opinioni, emozioni e atteggiamenti degli utenti.
- Estrarre insight da grandi quantità di testo non strutturato.
- Supportare decisioni basate sui feedback reali.

Applicazioni

- Analisi delle recensioni di prodotti e servizi
- Monitoraggio dei social media
- Customer experience e assistenza clienti

Metodi

- Approcci basati su regole e dizionari emotivi
 - Modelli di Machine Learning o modelli linguistici avanzati (Transformers)

Sentiment Analysis: Rule Based

Approccio basato su **dizionari** di **parole** associate a **polarità** (positive/negative) e **regole linguistiche** per determinare il sentiment di un testo.

Punti di forza

- Controllo totale sulle regole e sulla logica decisionale
- Trasparenza e interpretabilità del modello
- Funziona bene in domini ristretti e con linguaggio controllato
- Nessun bisogno di dataset etichettati

Limiti

- Scarsa capacità di gestire sarcasmo, ironia e contesto complesso
- Richiede manutenzione continua dei dizionari
- Bassa generalizzazione quando il dominio cambia
- Rigidità nelle regole → risultati poco flessibili

Perché testare diversi tool

- Ogni tool rule-based utilizza **dizionari**, **regole** e **strategie** diverse
- Le **performance** possono variare molto in base al **dominio** (es. social vs. recensioni tecniche)
- **Test multipli** permettono di trovare il sistema con la miglior **copertura linguistica** e la **polarità** più affidabile per il proprio caso d'uso

Approccio basato su architetture **deep learning** (es. BERT, RoBERTa, DistilBERT) capaci di **catturare il contesto** completo di una frase tramite meccanismi di **self-attention** -> analisi del sentiment più accurate e sfumate.

Punti di forza

- Comprensione avanzata del contesto e delle relazioni tra parole
- Elevata accuratezza anche su testi complessi e informali
- Capacità di generalizzare bene su domini diversi
- Possibilità di fine-tuning su dataset specifici

Limiti

- Richiedono potenza computazionale significativa
- Necessità di grandi quantità di dati se si fa fine-tuning
- Possibili bias appresi dai dati di addestramento
- Interpretabilità limitata rispetto ai modelli rule-based

Perché testare diversi tool

- Ogni **modello** (BERT, RoBERTa, XLM-R, GPT-based ecc.) ha punti di forza diversi
- Le **prestazioni** cambiano molto in base alla **lingua**, al **dominio** e alla **quantità** di testo
- Test comparativi permettono di identificare trade-off tra accuratezza, speed e risorse computazionali
- Scegliere il modello più adatto massimizza la qualità del sentiment nel contesto reale

Vectorizing Text

Processo che trasforma il testo in rappresentazioni numeriche utilizzabili dai modelli di Machine Learning.

Bag-of-Words (BoW)

Descrizione

Rappresenta i testi contando la frequenza delle parole, ignorando l'ordine.

Punti di forza

- Semplice da implementare
- Efficace per modelli lineari
- Veloce e interpretabile

Limiti

- Nessuna informazione sul contesto
- Vocabolario molto grande
- Sensibile al rumore e alle varianti linguistiche

COUNTS WHICH WORDS APPEAR IN WHICH DOCUMENTS

	about	bird	heard	is	the	word	you	yellow
About the bird, the bird is yellow	1	1	0	1	1	0	0	1
You heard about the bird	1	1	1	0	1	0	1	0
The bird is the word	0	1	0	1	1	1	0	0


Processo che trasforma il testo in rappresentazioni numeriche utilizzabili dai modelli di Machine Learning.

TF-IDF (Term Frequency – Inverse Document Frequency)

Descrizione

Pondera le parole in base alla loro importanza:

alta frequenza nel documento, bassa frequenza nel corpus.



Punti di forza

- Riduce l'impatto delle parole molto comuni
- Migliora la discriminazione tra documenti
- Mantiene semplicità e interpretabilità

Limiti

- Ancora "context-free", ignora la semantica
- Sensibile al vocabolario e alla sparsità
- Meno efficace su testi lunghi o complessi

Il **topic modelling** lavora su un **set di documenti** (o porzioni di testo) allo scopo di identificare patterns al fine di **raggruppare** tali documenti in base ai loro **topic** ed è un esempio di unsupervised learning

Word patterns vengono utilizzati per capire di cosa, ogni porzione di testo sta parlando.

Example of usage:

Categorizzare Notizie

Categorizzare recensioni di prodotti

AI is now able to create videos and audio that are hard to distinguish from the real thing. Recently, a number of celebrities have been impersonated and journalists need to take extra care, verifying sources before going to publication. You don't need any special hardware to work with AI. Governments are discussing bringing in regulations and policy

TOPIC 1 - EQUIPMENT

TOPIC 2 - MEDIA

TOPIC 3 - GOVERNMENT

Topic Modelling: Latent Dirichlet Distribution

Quando un articolo si concentra su un topic principale con solo poche parole riferite ad argomenti diversi. Gli argomenti latent sono quelli inespressi: LDA lavora sulla premessa che documenti che trattano lo stesso topic hanno molte parole in comune.

È basato su un meccanismo iterativo in cui i topic vengono assegnati alle parole e iterativamente corretti

Output: viene restituita una serie di indici in cui per ogni topic (indice) vengono riportate le parole ad esso associate.

FIRST ITERATION $k = 2$


data	Software	pollution	internet	Digital	oceans
k_1	k_2	k_2	k_2	k_1	k_1

SECOND ITERATION

data	Software	pollution	internet	Digital	oceans
k_1	k_2	k_2	k_2	k_1	k_1



LOOKING AT THE PROPORTION OF
WORDS IN THE CURRENT DOC




NUMBER OF TIMES THIS WORD IS
ASSIGNED TO A TOPIC IN OTHER DOCUMENTS

Topic Modelling: Latent Semantic Analysis

LSA riformula i dati testuali in termini di r features latenti (ovvero nascoste), dove r è minore di m , il numero di termini nei dati. LDA si basa su due punti fondamentali:

- Parole con significato simile appaiono frequentemente insieme
- Single Value Decomposition

Output: viene restituita una serie di indici in cui per ogni topic (indice) vengono riportate le parole ad esso associate.



Text Classifier
